

# Прикладная статистика в машинном обучении

## Лекция 1

И. К. Козлов  
(Мехмат МГУ)

2022

# Прикладная статистика в машинном обучении

В 1ой половине курса обсуждаются различные способы оценивания параметров и проверки гипотез.

- ① Введение. Точечные оценки. Метод максимального правдоподобия.
- ② Вероятностный взгляд на машинное обучение.
- ③ Интервальные оценки. Бутстреп.
- ④ Проверка гипотез. Множественное тестирование гипотез.
- ⑤ Регрессионный анализ.
- ⑥ Непараметрическое оценивание.
- ⑦ A/B-тестирование.

# Прикладная статистика в машинном обучении

2ая половина курса посвящена байесовскому подходу.

- ⑧ Байесовский подход к теории вероятности. Теорема Байеса. Аналитический байесовский вывод.
- ⑨ Байесовский взгляд на подбор моделей.
- ⑩ Метод релевантных векторов (RVM).
- ⑪ Модели с латентными переменными. EM-алгоритм.
- ⑫ Генеративные модели.

## Сколько мучиться

- ① 12 лекций и семинаров.
- ② 3 теоретических задания.
- ③ 3 лабораторные работы.

Не очень жёстко

## Жёсткость дедлайна.

Задание можно досдавать неделю после дедлайна.

$$\text{Штраф} = \min(50\%, 10\% * \text{число дней просрочки})$$

## Оценки

Экзамена нет!





Рис.: Итоговая оценка

# Standing on the shoulders of giants

Этот курс во многом основан на лекциях ШАД.



(a) А. М. Райгородский



(b) Е. В. Бурнаев



(c) Д. П. Ветров

Рис.: Лекторы, которым я благодарен

# Литература

Некоторые полезные книжки:

-  Wasserman L.  
*All of Nonparametric Statistics.*
-  Wasserman L.  
*All of Statistics.*
-  Bishop C.M.  
*Pattern Recognition and Machine Learning.*
-  Murphy K.P.  
*Machine Learning: A Probabilistic Perspective.*
-  М. Б. Лагутин,  
*Наглядная математическая статистика.*

## Базовый тервер

Базовые факты по теории вероятностей см. в Приложении к



М. Б. Лагутин,

*Наглядная математическая статистика.*

или в начале книжки Вассермана



Wasserman L.

*All of Nonparametric Statistics.*

## Стандартные обозначения


Распределения будут либо дискретными, либо абсолютно непрерывными.

Обозначения стандартные:

- $F(x)$  — функция распределения.
- $f(x)$  — плотность распределения (непр.) или функция вероятности (дискр.)

## Матожидание и дисперсия

Матожидание и дисперсия — вероятностные аналоги центра масс и момента инерции относительно него.



$$I = \sum m_i r_i^2$$

## Матожидание и дисперсия

Матожидание  $a(x)$  — либо интеграл, либо конечная сумма:

$$\mathbb{E}(a(x)) = \int a(x) dF(x) = \begin{cases} \int a(x)f(x)dx, & \text{непрерывный случай,} \\ \sum_j a(x_j)f(x_j), & \text{дискретный случай.} \end{cases}$$

Дисперсия:

$$\mathbb{V}(X) = \mathbb{E}(X - \mathbb{E}(X))^2.$$

# Что такое статистика?

## 1 Введение

- Что такое статистика?
- Непараметрическая статистика

## 2 Способы оценки параметров

- Точечная оценка
- Доверительные интервалы
- Проверка гипотез

## 3 Метод максимального правдоподобия

## 4 Байесовский подход

## 5 Резюме 1ой лекции

## Основная задача статистики

Основной вопрос статистики:

Дана выборка  $X_1, \dots, X_n \sim F$ .  
Что можно сказать о  $F$ ?

## Статистическая модель

- Статистическая модель. Фиксируем семейство распределений

$$\mathcal{F} = \{F_\theta(x), \quad \theta \in \Theta\},$$

в котором лежит  $F$ .

- Задача: восстановить распределение  $F_\theta$  (оценить параметры  $\theta$ ).

# Основная задача статистики

## Пример 1.

Курс будет по возможности наглядным и иметь отношение к ML.

Поговорим о деньгах.



## Пример с деньгами

Курс будет по возможности наглядным и иметь отношение к ML.

Поговорим о ~~деньгах~~ монетках.



## Орел и решка

Распределение Бернулли Bernoulli( $p$ ). Орёл выпадает с вероятностью  $p$ .



Реализация выборки — исходы бросков монетки.

Параметр  $p = ?$

Пусть  $X_1, \dots, X_n$  — i.i.d. и  $\mu = \mathbb{E}X_1 < \infty$ .

Обозначим

$$\bar{X}_n = \frac{X_1 + \dots + X_n}{n}.$$

Закон больших чисел

$$\bar{X}_n \xrightarrow{\mathbb{P}} \mu.$$

## Для тех, кто забыл

Случайные величины  $X_1, \dots, X_n$  сходятся при  $n \rightarrow \infty$  к случайной величине  $X$

- по вероятности  $X_n \xrightarrow{\mathbb{P}} X$ , если  $\forall \epsilon > 0$

$$\mathbb{P}(|X_n - X| > \epsilon) \rightarrow 0;$$

- почти наверное  $X_n \xrightarrow{a.s.} X$ , если

$$\mathbb{P}\{\omega : X_n(\omega) \rightarrow X(\omega)\} = 1;$$

- в среднем квадратичном  $X_n \xrightarrow{l^2} X$ , если

$$\mathbb{E}(X_n - X)^2 \rightarrow 0;$$

- по распределению  $X_n \xrightarrow{d} X$ , если

$$F_{X_n}(x) \rightarrow F_X(x)$$


для каждой точки непрерывности  $x$  функции распределения  $F_X(x)$ .

## Нормальный пример

### Пример 2.

Определить параметры  $\mu$  и  $\sigma$  у стандартного нормального распределения

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}$$



Нормальное распределение повсюду!

Центральная предельная теорема.

Если  $\mathbb{V}X_i = \sigma^2 < \infty$ , то

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2).$$

## Первая развилка



Рис.: Возникает 1ая развилка

Конечномерно ли пространство параметров  $\Theta$ ?

## Статистика

$\dim \Theta < \infty$



$\dim \Theta = \infty$

Параметрическая

Непараметрическая

# Непараметрическая статистика

## 1 Введение

- Что такое статистика?
- Непараметрическая статистика

## 2 Способы оценки параметров

- Точечная оценка
- Доверительные интервалы
- Проверка гипотез

## 3 Метод максимального правдоподобия

## 4 Байесовский подход

## 5 Резюме 1ой лекции

# Непараметрическая статистика

Задачи непараметрической статистики?

- Даны выборка  $X_1, \dots, X_n \sim F$ .

Как восстановить функцию распределения

$$F(x) = \mathbb{P}(X \leq x)?$$

Или плотность  $f(x)$ ?

# Непараметрическая статистика

Задачи непараметрической статистики?

- Даны выборка  $X_1, \dots, X_n \sim F$ .

Как восстановить функцию распределения

$$F(x) = \mathbb{P}(X \leq x)?$$


Или плотность  $f(x)$ ?

Q: Важнейший результат об этом?

# Эмпирическая функция распределений

## Эмпирическая функция распределения

$$\hat{F}(x) = \frac{\text{кол-во эл-тов в выборке} \leq x}{n} = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x).$$



## Теорема Гливенко-Кантелли

### Теорема Гливенко-Кантелли

$$\sup_{x \in \mathbb{R}} |\hat{F}(x) - F(x)| \xrightarrow{a.s.} 0 .$$

## Непараметрическая статистика

Другая задача непараметрической статистики:

- Оценить статистики распределения  $T(F)$ , например матожидание

$$T(F) = \int x dF(x).$$

## Непараметрическая статистика

Другая задача непараметрической статистики:

- Оценить статистики распределения  $T(F)$ , например матожидание

$$T(F) = \int x dF(x).$$

Q: Простейший способ это сделать?

# Лекция 1

Статистический функционал  $T(F)$  — это функция от распределения  $F$ .

Примеры:

- Среднее значение

$$\mu = \int x dF(x),$$

- Дисперсия

$$\sigma^2 = \int (x - \mu)^2 dF(x),$$

- Медиана (квантиль распределения)

$$m = F^{-1}\left(\frac{1}{2}\right).$$

## Plug-in оценивание

**Выборочные оценки** — подставить в интеграл эмпирическую функцию распределения  $\hat{F}$ .

Интеграл превращается в сумму

$$T(\hat{F}_n) = \int a(x) d\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n a(X_i).$$

## Регрессия

Ещё одна задача непараметрической статистики:

- **Регрессия.** Даны пары  $(x_1, Y_1), \dots, (x_n, Y_n)$ , где

$$Y_i = r(x_i) + \varepsilon_i, \quad \text{и} \quad \mathbb{E}\varepsilon_i = 0.$$

Нужно восстановить функцию регрессии  $r$ .

# Логистическая регрессия

Да, линейную и логистическую регрессию мы тоже обсудим.



Install User Guide API Examples More ▾

Prev Up Next

scikit-learn 1.0.2  
Other versions

Please cite us if you use the software.

## sklearn.linear\_model.LogisticRegression

```
class sklearn.linear_model.LogisticRegression(penalty='l2', *, dual=False, tol=0.0001, C=1.0, fit_intercept=True, intercept_scaling=1, class_weight=None, random_state=None, solver='lbfgs', max_iter=100, multi_class='auto', verbose=0, warm_start=False, n_jobs=None, l1_ratio=None)
```

[source]

Logistic Regression (aka logit, MaxEnt) classifier.

sklearn.linear\_model.LogisticRegression

# Точечная оценка

## 1 Введение

- Что такое статистика?
- Непараметрическая статистика

## 2 Способы оценки параметров

- Точечная оценка
- Доверительные интервалы
- Проверка гипотез

## 3 Метод максимального правдоподобия

## 4 Байесовский подход

## 5 Резюме 1ой лекции

## Оценки параметров

3 важнейших способа оценивать параметры:

- Точечная оценка.
- Доверительные интервалы.
- Проверка гипотез.

## Точечная оценка

### Точечная оценка.

Оценка параметра  $\theta$  — случайная величина от выборки

$$\hat{\theta}_n = g(X_1, \dots, X_n).$$

По традиции обозначается  $\hat{\theta}$  или  $\hat{\theta}_n$ .

## Несмешённость

Что мы хотим от оценки?

- Смещение оценки:

$$\text{Bias}_\theta(\hat{\theta}_n) = \mathbb{E}_\theta(\hat{\theta}_n) - \theta$$

Q. Почему написано  $\mathbb{E}_\theta$ ?


## Несмешённость

- $\mathbb{E}_\theta(\hat{\theta}_n)$  — среднее значение статистики  $\hat{\theta}$  по всем реализациям выборок  $X_1, \dots, X_n$  при фиксированном  $\theta$ .

## Несмешённость

- $\mathbb{E}_\theta(\hat{\theta}_n)$  — среднее значение статистики  $\hat{\theta}$  по всем реализациям выборок  $X_1, \dots, X_n$  при фиксированном  $\theta$ .


Пример. Кидаем монетку 2 раза.  $\hat{\theta}$  — доля выпавших орлов.



## Несмешённость

- $\mathbb{E}_\theta(\hat{\theta}_n)$  — среднее значение статистики  $\hat{\theta}$  по всем реализациям выборок  $X_1, \dots, X_n$  при фиксированном  $\theta$ .

Пример. Кидаем монетку 2 раза.  $\hat{\theta}$  — доля выпавших орлов.



$$\mathbb{E}_\theta(\hat{\theta}) = 0 * (1 - p)^2 + 2 * 0,5 * p(1 - p) + 1 * p^2 = p.$$

## Несмешённость

В общем случае

$$\mathbb{E}_\theta(\hat{\theta}_n) = \int g(x_1, \dots, x_n) f_\theta(x_1) \dots f_\theta(x_n) dx_1 \dots dx_n.$$

## Несмешённость

Оценка  $\hat{\theta}_n$  **несмешенная**, если  $\text{Bias}_{\theta}(\hat{\theta}_n) = 0$  для любого  $\theta$ .

Несмешённость — неплохо, но необязательно.

## Стандартная ошибка

Несмешённость = в среднем угадываем параметр.

Но ~~какой ценой~~ каков разброс?

Стандартная ошибка — корень из дисперсии

$$se = se(\hat{\theta}_n) = \sqrt{\mathbb{V}_{\theta}(\hat{\theta}_n)}.$$

## Состоятельность

Чем больше данных — тем меньше вероятность сильного отклонения оценки.

- Оценка  $\hat{\theta}_n$  **состоятельная**, если

$$\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta$$

## Состоятельность

Чем больше данных — тем меньше вероятность сильного отклонения оценки.

- Оценка  $\hat{\theta}_n$  **состоятельная**, если

$$\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta$$

Напомним, сходимость по вероятности:

$$\mathbb{P}(|\hat{\theta}_n - \theta| > \epsilon) \rightarrow 0, \quad \forall \epsilon > 0.$$


## Зависимость между видами сходимости

**Q:** Как проверять состоятельность оценки?

## Зависимость между видами сходимости

**Q:** Как проверять состоятельность оценки?

**Идея.** Вспомним зависимость между видами сходимости:



# MSE

- Среднеквадратичная ошибка

$$\text{MSE} = \mathbb{E}_\theta (\hat{\theta} - \theta)^2$$

## Теорема

$$\text{MSE} = (\text{Bias}_\theta(\hat{\theta}))^2 + \mathbb{V}_\theta(\hat{\theta}).$$

**Следствие.** Если  $\text{Bias}_\theta(\hat{\theta}) \rightarrow 0$  и  $\mathbb{V}_\theta(\hat{\theta}) \rightarrow 0$ , то  $\hat{\theta}$  — состоятельная оценка.

## Теорема

$$\text{MSE} = \mathbb{V}_\theta(\hat{\theta}) + (\text{Bias}_\theta(\hat{\theta}))^2.$$

**Доказательство.**

Обозначим  $\bar{\theta} = \mathbb{E}_\theta(\hat{\theta})$ .

Далее просто раскрываем скобки:

$$\text{MSE} = \mathbb{E}_\theta \left( \hat{\theta} - \bar{\theta} + \bar{\theta} - \theta \right)^2 =$$

## Bias-Variance trade-off

### Теорема

$$\text{MSE} = \mathbb{V}_\theta(\hat{\theta}) + (\text{Bias}_\theta(\hat{\theta}))^2.$$

**Доказательство.**

Обозначим  $\bar{\theta} = \mathbb{E}_\theta(\hat{\theta})$ .

Далее просто раскрываем скобки:

$$\begin{aligned}\text{MSE} &= \mathbb{E}_\theta \left( \hat{\theta} - \bar{\theta} + \bar{\theta} - \theta \right)^2 = \\ &= \mathbb{E}_\theta \left( \hat{\theta} - \bar{\theta} \right)^2 + 2 \left( \bar{\theta} - \theta \right) \mathbb{E}_\theta \left( \hat{\theta} - \bar{\theta} \right) + \mathbb{E}_\theta \left( \bar{\theta} - \theta \right)^2 =\end{aligned}$$

## Теорема

$$\text{MSE} = \mathbb{V}_\theta(\hat{\theta}) + (\text{Bias}_\theta(\hat{\theta}))^2.$$

**Доказательство.**

Обозначим  $\bar{\theta} = \mathbb{E}_\theta(\hat{\theta})$ .

Далее просто раскрываем скобки:

$$\begin{aligned}\text{MSE} &= \mathbb{E}_\theta \left( \hat{\theta} - \bar{\theta} + \bar{\theta} - \theta \right)^2 = \\ &= \mathbb{E}_\theta \left( \hat{\theta} - \bar{\theta} \right)^2 + 2 \left( \bar{\theta} - \theta \right) \mathbb{E}_\theta \left( \hat{\theta} - \bar{\theta} \right) + \mathbb{E}_\theta \left( \bar{\theta} - \theta \right)^2 = \\ &= \mathbb{V}_\theta(\hat{\theta}) + \text{Bias}(\hat{\theta})^2.\end{aligned}$$

## К теореме Гливенко-Кантелли

**Пример.** Эмпирическая функция распределения  $\hat{F}_n(x)$  — несмещённая состоятельная оценка  $F(x)$  в каждой точке  $x$ .

### Теорема

Для любой фиксированной точки  $x$ :

$$\mathbb{E}(\hat{F}_n(x)) = F(x),$$

$$\mathbb{V}(\hat{F}_n(x)) = \frac{F(x)(1 - F(x))}{n},$$

## К теореме Гливенко-Кантелли

**Пример.** Эмпирическая функция распределения  $\hat{F}_n(x)$  — несмещённая состоятельная оценка  $F(x)$  в каждой точке  $x$ .

### Теорема

Для любой фиксированной точки  $x$ :

$$\mathbb{E}(\hat{F}_n(x)) = F(x),$$

$$\mathbb{V}(\hat{F}_n(x)) = \frac{F(x)(1 - F(x))}{n},$$

$$\text{MSE} = \frac{F(x)(1 - F(x))}{n} \rightarrow 0,$$

$$\hat{F}_n(x) \xrightarrow{\mathbb{P}} F(x).$$

## Асимптотическая нормальность

Зачастую нам достаточно выполнения статистических свойств в пределе.

Оценка  $\hat{\theta}_n$  асимптотически нормальна, если

$$\frac{\hat{\theta}_n - \theta}{\text{se}} \xrightarrow{d} \mathcal{N}(0, 1).$$

# Доверительные интервалы

## 1 Введение

- Что такое статистика?
- Непараметрическая статистика

## 2 Способы оценки параметров

- Точечная оценка
- Доверительные интервалы
- Проверка гипотез

## 3 Метод максимального правдоподобия

## 4 Байесовский подход

## 5 Резюме 1ой лекции

## Точечные оценки не идеальны

Монету подбросили 15 раз. Выпало

4 орла,      11 решек.

Готовы дать руку на отсечение, что  $p = \frac{4}{15}$ ?

## Доверительный интервал

Доверительный интервал с доверительной вероятностью  $1 - \alpha$  для параметра  $\theta$  — это интервал

$$C_n = (a, b), \quad a = a(X_1, \dots, X_n), \quad b = b(X_1, \dots, X_n),$$

для которого

$$P_\theta(\theta \in C_n) \geq 1 - \alpha, \quad \text{для всех } \theta \in \Theta.$$

Подробнее поговорим про доверительные интервалы на [Лекции 3](#).

## Brace yourself

Для построения точных доверительных интервалов нужно найти то или иное неравенство.




Рис.: Неравенства страшные

## Неравенство Хёфдинга

Неравенство для отклонения от матожидания суммы ограниченных с.в.<sup>1</sup>:

### Неравенство Хёфдинга

Пусть  $X_1, \dots, X_n$  — i.i.d. и  $a_i \leq X_i \leq b_i$ . Положим

$$S_n = X_1 + \dots + X_n.$$

Тогда для любого  $t > 0$

$$\mathbb{P}(S_n - \mathbb{E}[S_n] \geq t) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right)$$

$$\mathbb{P}(|S_n - \mathbb{E}[S_n]| \geq t) \leq 2 \exp\left(-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right)$$


<sup>1</sup> Применимо для распределения Бернулли

## Dvoretzky–Kiefer–Wolfowitz–Massart inequality

Для эмпирической функции распределения:

### Dvoretzky–Kiefer–Wolfowitz–Massart inequality

$$\mathbb{P}\left(\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| > \varepsilon\right) \leq 2e^{-2n\varepsilon^2} \quad \text{для любого } \varepsilon > 0.$$



# Проверка гипотез

## 1 Введение

- Что такое статистика?
- Непараметрическая статистика

## 2 Способы оценки параметров

- Точечная оценка
- Доверительные интервалы
- Проверка гипотез

## 3 Метод максимального правдоподобия

## 4 Байесовский подход

## 5 Резюме 1ой лекции

## Проверка гипотез

Частый вопрос — насколько маловероятно то или иное значение  $\theta = \theta_0$ ?

**Пример.** Пусть

$$X_1, \dots, X_n \sim \text{Bernoulli}(p).$$

- **Нулевая гипотеза**  $H_0$ : обмана нет  $p = \frac{1}{2}$ .
- **Альтернативная гипотеза**  $H_1$ :  $p \neq \frac{1}{2}$ .

Обсудим проверки гипотез в [Лекции 4](#).

# Метод максимального правдоподобия

## 1 Введение

- Что такое статистика?
- Непараметрическая статистика

## 2 Способы оценки параметров

- Точечная оценка
- Доверительные интервалы
- Проверка гипотез

## 3 Метод максимального правдоподобия

## 4 Байесовский подход

## 5 Резюме 1ой лекции

## Вспомним всё

Вспомним, как решаются статистические задачи.

Вспомним всё

Вспомним, как решаются статистические задачи.



Всё будет *нормально* и **максимально правдоподобно**.

# MLE

- Известна плотность вероятности:

$$\mathcal{F} = \{f(x, \theta), \theta \in \Theta\}$$

- Функция правдоподобия = вероятность выборки

$$\mathcal{L}_n(\theta) = \prod_{i=1}^n f(X_i; \theta).$$

- Оценка максимального правдоподобия (MLE)

$$\hat{\theta}_{ML} = \arg \max_{\theta \in \Theta} \mathcal{L}_n(\theta).$$

## Логарифмируем произведение

На практике **малые величины лучше суммировать, чем перемножать.**

### Логарифм функции правдоподобия

$$\ell_n(\theta) = \log \mathcal{L}_n(\theta).$$

## Заметём под ковёр

Свойства МЛЕ верны при определённых **условиях регулярности**.



Рис.: По традиции опустим их

## Строгие формулировки

Подробные формулировки и доказательство можно найти в



- R. Hogg, J. McKean, A. Craig,  
*Introduction to Mathematical Statistics*. Chapter 6.

## Простейший случай

Для простоты<sup>2</sup> предположим, что

- МЛЕ существует и единственна;
- $\hat{\theta}_{ML}$  — внутренняя точка  $\Theta$ , и это единственное решение

$$\frac{\partial L(\theta)}{\partial \theta} = 0;$$

- функции  $f(x; \theta)$  и  $\int f(x; \theta)$  дважды дифференцируемы по  $\theta$  (и производную можно вносить под знак интеграла).

---

<sup>2</sup>Это не все условия. Некоторые условия можно ослабить.

## MLE инвариантна

- MLE инвариантна.

Если  $\tau = g(\theta)$  и  $\hat{\theta}_{ML}$  — ML оценка для  $\theta$ , то  $\hat{\tau} = g(\hat{\theta}_{ML})$  — ML оценка для  $\tau$ .

Если  $g$  — биекция, то очевидно.

$$\mathcal{L}(\theta) = \mathcal{L}(\tau),$$

при замене координат максимум переходит в максимум.

Можно доказать для любой  $g$ .

## MLE состоятельна

- MLE состоятельна

$$\hat{\theta}_{ML} \xrightarrow{\mathbb{P}} \theta$$

## MLE состоятельна

- MLE состоятельна

$$\hat{\theta}_{ML} \xrightarrow{\mathbb{P}} \theta$$

Далее для простоты  $\dim \Theta = 1$  (параметр  $\theta$  — число).

Следующее свойство — асимптотическая нормальность. Для оценки дисперсии нужно ввести несколько функций.

# Информация Фишера

- Функция оценки

$$s(X; \theta) = \frac{\partial \log f(X; \theta)}{\partial \theta}.$$

- Информация Фишера

$$I_n(\theta) = \mathbb{V}\left(\sum_{i=1}^n s(X_i; \theta)\right) = \sum_{i=1}^n \mathbb{V}(s(X_i; \theta))$$

Часто обозначают  $I_1(\theta) = I(\theta)$ . Тогда  $I_n(\theta) = n I(\theta)$ .

## Асимптотическая нормальность

- MLE асимптотически нормальна

$$\sqrt{n}(\hat{\theta}_{ML} - \theta) \xrightarrow{d} \mathcal{N}\left(0, \frac{1}{I(\theta)}\right).$$

Матрицу Фишера можно заменить её оценкой

$$\frac{\hat{\theta}_{ML} - \theta}{\hat{s}\hat{e}} \xrightarrow{d} \mathcal{N}(0, 1), \quad \hat{s}\hat{e}^2 = \frac{1}{I_n(\hat{\theta}_{ML})}.$$

## Асимптотическая нормальность

- MLE асимптотически нормальна

$$\sqrt{n}(\hat{\theta}_{ML} - \theta) \xrightarrow{d} \mathcal{N}\left(0, \frac{1}{I(\theta)}\right).$$

Матрицу Фишера можно заменить её оценкой

$$\frac{\hat{\theta}_{ML} - \theta}{\hat{\text{se}}} \xrightarrow{d} \mathcal{N}(0, 1), \quad \hat{\text{se}}^2 = \frac{1}{I_n(\hat{\theta}_{ML})}.$$

Итак, MLE асимптотически несмешена и дисперсия примерно равна  $\frac{1}{I_n(\theta)}$ .

## Неравенство Рао–Крамера

### Неравенство Рао–Крамера

Пусть выполнены условия регулярности, а  $T$  — функция от выборки. Тогда

$$\mathbb{V}(T) \geq \frac{1}{I_n(\theta)} \left( \frac{\partial \mathbb{E}(T)}{\partial \theta} \right)^2.$$

## Неравенство Рао–Крамера

### Неравенство Рао–Крамера

Пусть выполнены условия регулярности, а  $T$  — функция от выборки. Тогда

$$\mathbb{V}(T) \geq \frac{1}{I_n(\theta)} \left( \frac{\partial \mathbb{E}(T)}{\partial \theta} \right)^2.$$

Для несмешённых оценок  $\mathbb{E}(\hat{\theta}) = \theta$  получаем

$$\mathbb{V}(\hat{\theta}) \geq \frac{1}{I_n(\theta)}.$$

## MLE оптимальна

Оптимальная оценка — несмешённая оценка с минимальной дисперсией.

- MLE асимптотически оптимальна.

- ▶ Она асимптотически несмешенна (т.к. асимпт. норм.)
- ▶ Её дисперсия стремится к  $\mathbb{V}(\hat{\theta}) \geq \frac{1}{I_n(\theta)}$ .
- ▶ По неравенству Рао-Крамера дисперсия  $\geq \mathbb{V}(\hat{\theta}) \geq \frac{1}{I_n(\theta)}$ .

# Байесовский подход

## 1 Введение

- Что такое статистика?
- Непараметрическая статистика

## 2 Способы оценки параметров

- Точечная оценка
- Доверительные интервалы
- Проверка гипотез

## 3 Метод максимального правдоподобия

## 4 Байесовский подход

## 5 Резюме 1ой лекции

## Допустимый уровень ошибок

**Q:** Какой доверительный интервал взять?

## Допустимый уровень ошибок

Q: Какой доверительный интервал взять?

A: 95% или 99%.

Это традиция)

## Многомодальность

Почему мы ограничиваемся интервалом для  $\theta$ ?





Рис.: У  $\theta$  могут быть разные моды




Идея. Значение  $\theta$  определяется распределением  $p(\theta)$ .

И треснул мир на пополам

## 2 подхода к статистике:



Частотный



Байесовский

## Формула Байеса

При поступлении данных от априорного распределения  $p(\theta)$  мы переходим к апостериорному  $P(\theta | X)$ .

## Формула Байеса

$$P(\theta | X) = \frac{P(X | \theta) P(\theta)}{\int P(X | \theta) P(\theta) d\theta}.$$

Обсудим байесовский подход [во 2ой части курса](#).

# Резюме 1ой лекции

## 1 Введение

- Что такое статистика?
- Непараметрическая статистика

## 2 Способы оценки параметров

- Точечная оценка
- Доверительные интервалы
- Проверка гипотез

## 3 Метод максимального правдоподобия

## 4 Байесовский подход

## 5 Резюме 1ой лекции

## Дilemma смещения–дисперсии

$$MSE(\hat{\theta}) = \text{Var}_{\theta}(\hat{\theta}) + \text{Bias}_{\theta}(\hat{\theta})^2.$$

Одна из ключевых проблем в обучении с учителем (**переобучение**).




Рис.: Bias-variance tradeoff

# Оценка максимального правдоподобия

Оценка максимального правдоподобия

$$\hat{\theta}_{ML} = \arg \max_{\theta \in \Theta} \mathcal{L}_n(\theta)$$

- Состоятельна.
- Инвариантна.
- Асимптотически нормальна.
- Асимптотически оптимальна.

## Разделы статистики

	Parametric	Nonparametric
Frequentist	I	II
Bayesian	III	Будет в ШАД (Гауссовские процессы)

Рис.: Разделы статистики, которые мы обсудим

To be continued

	Parametric	Nonparametric
Frequentist	I	II
Bayesian	III	Будет в ШАД (Гауссовские процессы)

← To Be Continued III