

Прикладная статистика в машинном обучении

Семинар 2

И. К. Козлов
(Мехмат МГУ)

2022

Упражнения с прошлого занятия

1 Упражнения с прошлого занятия

2 Вопросы про ML

3 Псевдообратная матрица

4 Линейная регрессия

Семинар 2

Докажем смещённость выборочной дисперсии

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Семинар 2

Докажем смещённость выборочной дисперсии

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Доказательство:

$$\mathbb{E}S^2 = \mathbb{E}\left(\frac{1}{n}X_i^2 - \frac{1}{n^2} \sum_{i,j} X_i X_j\right) =$$

Семинар 2

Докажем смещённость выборочной дисперсии

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Доказательство:

$$\begin{aligned} \mathbb{E}S^2 &= \mathbb{E}\left(\frac{1}{n}X_i^2 - \frac{1}{n^2} \sum_{i,j} X_i X_j\right) = \\ &= \frac{1}{n} \mathbb{E}X_i^2 - \frac{1}{n^2} \mathbb{E}X_i^2 - \frac{1}{n^2} \sum_{i \neq j} \mathbb{E}X_i \mathbb{E}X_j = \end{aligned}$$

Семинар 2

Докажем смещённость выборочной дисперсии

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Доказательство:

$$\mathbb{E}S^2 = \mathbb{E}\left(\frac{1}{n}X_i^2 - \frac{1}{n^2} \sum_{i,j} X_i X_j\right) =$$


$$= \frac{1}{n} \mathbb{E}X_i^2 - \frac{1}{n^2} \mathbb{E}X_i^2 - \frac{1}{n^2} \sum_{i \neq j} \mathbb{E}X_i \mathbb{E}X_j =$$

$$\frac{1}{n} \mathbb{E}X_1^2 - \frac{1}{n} \mathbb{E}X_i^2 - \frac{n-1}{n} (\mathbb{E}X_1)^2 = \frac{n-1}{n} \mathbb{V}X_1.$$

Эмпирическая функция распределений

Эмпирическая функция распределения

$$\hat{F}(x) = \hat{F}_n(x) = \frac{\text{кол-во эл-тов в выборке} \leq x}{n} = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x).$$



Утверждение:

$$\mathbb{E}(\hat{F}_n(x)) = F(x),$$

Утверждение:

$$\mathbb{E}(\hat{F}_n(x)) = F(x),$$

Доказательство: Нужно вспомнить стандартные формулы.

- Формула для эмпирической функции распределения

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x).$$

- Вспоминаем формулу для матожидания

$$\mathbb{E}(a(x)) = \int a(x) dF(x) = \int a(x) f(x) dx$$

- Вспоминаем формулу для матожидания

$$\mathbb{E}(a(x)) = \int a(x) dF(x) = \int a(x) f(x) dx$$

Используем линейность матожидания:

$$\mathbb{E}\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{E} I(X_i \leq x) = \mathbb{E} I(X_1 \leq x).$$

- Вспоминаем формулу для матожидания

$$\mathbb{E}(a(x)) = \int a(x) dF(x) = \int a(x) f(x) dx$$

Используем линейность матожидания:

$$\mathbb{E} \hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{E} I(X_i \leq x) = \mathbb{E} I(X_1 \leq x).$$

Считаем матожидание:

$$\mathbb{E} I(X \leq x) = \int_{-\infty}^{\infty} I(z \leq x) f(z) dz = \int_{-\infty}^x f(z) dz$$

- Осталось вспомнить формулу для функции распределения

$$F(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f(z) dz$$

Утверждение доказано.

Утверждение:

$$\mathbb{V}(\hat{F}_n(x)) = \frac{F(x)(1-F(x))}{n}$$

Семинар 2

Утверждение:

$$\mathbb{V}(\hat{F}_n(x)) = \frac{F(x)(1-F(x))}{n}$$

Доказательство.

- Вспоминаем формулу дисперсии

$$\mathbb{V}(X) = \mathbb{E}(X)^2 - (\mathbb{E}X)^2.$$

- Мы знаем, что $\mathbb{E}(\hat{F}_n(x)) = F(x)$, осталось посчитать $\mathbb{E}(\hat{F}_n(x))^2$.

- Подставляем формулу для эмпирической функции распределения

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x).$$

Для краткости обозначим

$$I_i = I(X_i \leq x)$$

Получаем

$$\mathbb{E}(\hat{F}_n(x))^2 = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n I_i\right)^2 = \frac{1}{n^2} \left(\sum_{i=1}^n \mathbb{E} I_i^2 + \sum_{i \neq j} \mathbb{E}(I_i I_j) \right).$$

Семинар 2

- В 1ом слагаемом $l_i^2 = l_i$, т.к. это индикатор:

$$\frac{1}{n^2} \sum_{i=1}^n \mathbb{E} l_i^2 = \frac{1}{n^2} \sum \mathbb{E} l_i = \frac{1}{n} F(x).$$

Семинар 2

Во 2ом слагаемом $\sum_{i \neq j} \mathbb{E}(I_i I_j)$ вспоминаем 2 факта:

- (Борелевские) функции от независимых случайных величин независимы.
- Если X и Y — независимы, то

$$\mathbb{E}(XY) = \mathbb{E}X \mathbb{E}Y.$$

Семинар 2

Во 2ом слагаемом $\sum_{i \neq j} \mathbb{E}(I_i I_j)$ вспоминаем 2 факта:

- (Борелевские) функции от независимых случайных величин независимы.
- Если X и Y — независимы, то

$$\mathbb{E}(XY) = \mathbb{E}X \mathbb{E}Y.$$

Поэтому

$$\frac{1}{n^2} \sum_{i \neq j} \mathbb{E}(I_i I_j) = \frac{1}{n^2} \mathbb{E}I_i \mathbb{E}I_j = \frac{n^2 - n}{n^2} F(x)^2.$$

Семинар 2

Подставляем все вычисленные значения в формулу для дисперсии.

Получаем требуемый ответ:

$$\begin{aligned}\mathbb{V}(\hat{F}_n(x)) &= \frac{1}{n}F(x) + \frac{n^2 - n}{n^2}F(x)^2 - F(x)^2 = \\ &= \frac{F(x)}{n} - \frac{F(x)^2}{n} = \frac{F(x)(1 - F(x))}{n}\end{aligned}$$

Вопросы про ML

1 Упражнения с прошлого занятия

2 Вопросы про ML

3 Псевдообратная матрица

4 Линейная регрессия

Логистическая регрессия

Logloss = Cross Entropy:

$$L_{\log}(y, p) = - \sum_i (y_i \log p_i + (1 - y_i) \log(1 - p_i))$$

- $y_i \in \{0, 1\}$ — истинные метки классов,
- $p_i = \mathbb{P}(y_i = 1)$ — вероятностные предсказания модели,

Q: Откуда взялся этот лосс?

Логлосс

А: Вспомним функцию правдоподобия для Bernoulli (p):

$$\mathcal{L} = p^x (1 - p)^{1-x}.$$

Логарифм правдоподобия даёт минус логлосс:

$$\ell = x \log p + (1 - x) \log(1 - p).$$

Для сравнения логлосс:

$$L_{\log}(y, p) = - \sum_i (y_i \log p_i + (1 - y_i) \log(1 - p_i)).$$

SVD-разложение:

$$A = U \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} V^T$$

Любая матрица $m \times n$ Ортогональная $m \times m$ Диагональная $m \times n$ Ортогональная $n \times n$


$$\sigma_1 \geq \dots \geq \sigma_r > 0$$

Напомним, матрица U ортогональная, если $U^T U = E$.

Сингулярное разложение

Q: Для чего в ML может применять сингулярное разложение? Кроме линейной/логистической регрессии

A: Уменьшение размерности. См. Метод главных компонент **PCA**



Сингулярное разложение

Пусть SVD-разложение:

$$A = U\Sigma V^T,$$
$$\Sigma = (\sigma_1, \dots, \sigma_r, 0, \dots, 0).$$

Если u_i — столбцы U , а v_i — строки V^T , то


$$A = \sum_{i=1}^r \sigma_i u_i v_i^T.$$

Сингулярное разложение

В диагональной матрице можно обнулить последние коэффициенты.

$$\sigma_{k+1} \rightarrow 0, \quad \dots \quad \sigma_r \rightarrow 0$$

Получится экономия по памяти.



Псевдообратная матрица

- 1 Упражнения с прошлого занятия
- 2 Вопросы про ML
- 3 Псевдообратная матрица**
- 4 Линейная регрессия

Псевдообратная матрица

Формулы для псевдообратной матрицы A^+ :

- Если столбцы A линейно независимы.

$$A^+ = (A^T A)^{-1} A^T.$$

- Если строки A линейно независимы:

$$A^+ = A^T (A A^T)^{-1}.$$

Логистическая регрессия

Q: Почему

$$\text{rk } A = \text{rk } A^T A?$$

Что такое матрица $A^T A$?

Логистическая регрессия

Q: Почему

$$\text{rk } A = \text{rk } A^T A?$$

Что такое матрица $A^T A$?

A: $A^T A$ — это матрица Грамма для столбцов.

$$\begin{pmatrix} a & c \\ b & d \end{pmatrix} \begin{pmatrix} a & b \\ c & d \end{pmatrix} = \begin{pmatrix} a^2 + c^2 & ac + bd \\ ac + bd & b^2 + d^2 \end{pmatrix}$$

Логистическая регрессия

Q: Почему

$$\operatorname{rk} A = \operatorname{rk} A^T A?$$

Что такое матрица $A^T A$?

A: $A^T A$ — это матрица Грамма для столбцов.

$$\begin{pmatrix} a & c \\ b & d \end{pmatrix} \begin{pmatrix} a & b \\ c & d \end{pmatrix} = \begin{pmatrix} a^2 + c^2 & ac + bd \\ ac + bd & b^2 + d^2 \end{pmatrix}$$

Вспоминаем линейную алгебру:

Ранг матрицы Грамма векторов v_1, \dots, v_N = размерности линейного подпространства, порождённого векторами v_i .

Логистическая регрессия

Q: Найти

$$\begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \dots & \dots \\ x_n & 1 \end{pmatrix}^+$$

Логистическая регрессия

Q: Найти

$$\begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \dots & \dots \\ x_n & 1 \end{pmatrix}^+$$

A: Применяем формулу

$$A^+ = (A^T A)^{-1} A^T.$$

Получаем

$$\begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \dots & \dots \\ x_n & 1 \end{pmatrix}^+ = \begin{pmatrix} n\bar{x}^2 & n\bar{x} \\ n\bar{x} & n \end{pmatrix}^{-1} \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ 1 & 1 & \dots & 1 \end{pmatrix} =$$

Логистическая регрессия

Q: Найти

$$\begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \dots & \dots \\ x_n & 1 \end{pmatrix}^+$$

A: Применяем формулу

$$A^+ = (A^T A)^{-1} A^T.$$

Получаем

$$\begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \dots & \dots \\ x_n & 1 \end{pmatrix}^+ = \begin{pmatrix} n\bar{x}^2 & n\bar{x} \\ n\bar{x} & n \end{pmatrix}^{-1} \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ 1 & 1 & \dots & 1 \end{pmatrix} =$$

$$\frac{1}{n} \frac{1}{\bar{x}^2 - \bar{x}^2} \begin{pmatrix} 1 & -\bar{x} \\ -\bar{x} & \bar{x}^2 \end{pmatrix} \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ 1 & 1 & \dots & 1 \end{pmatrix} = \frac{1}{n} \frac{1}{\bar{x}^2 - \bar{x}^2} \begin{pmatrix} x_1 - \bar{x} & x_2 - \bar{x} & \dots & x_n - \bar{x} \\ \bar{x}^2 - x_1\bar{x} & \bar{x}^2 - x_2\bar{x} & \dots & \bar{x}^2 - x_n\bar{x} \end{pmatrix}.$$

Линейная регрессия


- 1 Упражнения с прошлого занятия
- 2 Вопросы про ML
- 3 Псевдообратная матрица
- 4 Линейная регрессия**

Семинар 2

Простейшая линейная регрессия.

Пусть даны точки (x_i, y_i) , где $i = 1, \dots, N$. Аппроксимируем решение линейной функцией

$$y_i = kx_i + b$$



Семинар 2

Задача. Найти минимум MSE:

$$J = \frac{1}{N} \sum_i (y_i - (kx_i + b))^2.$$

Решение. Сумма выпуклых функций — выпуклая функция. Поэтому у лосса существует минимум, и его можно найти как решение

$$\frac{\partial J}{\partial k} = 0, \quad \frac{\partial J}{\partial b} = 0$$

Семинар 2

Вычисляем производные:

$$\frac{\partial J}{\partial k} = \frac{1}{N} \sum_i (y_i - (kx_i + b)) (-x_i),$$

$$\frac{\partial J}{\partial b} = \frac{1}{N} \sum_i (y_i - (kx_i + b)) (-1)$$

Из 2го уравнения находим

$$b = \bar{y} - k\bar{x}$$

Семинар 2

Вычисляем производные:

$$\frac{\partial J}{\partial k} = \frac{1}{N} \sum_i (y_i - (kx_i + b)) (-x_i),$$

$$\frac{\partial J}{\partial b} = \frac{1}{N} \sum_i (y_i - (kx_i + b)) (-1)$$

Из 2го уравнения находим

$$b = \bar{y} - k\bar{x}$$

Подставляем в 1ое уравнение

$$0 = -\bar{x}\bar{y} + k\bar{x}^2 - b\bar{x} = -\bar{x}\bar{y} + \bar{x}\bar{y} + k(\bar{x}^2 - \bar{x}^2)$$

Получаем **ответ**

$$k = \frac{\bar{x}\bar{y} - \bar{x}\bar{y}}{\bar{x}^2 - \bar{x}^2}, \quad b = \bar{y} - k\bar{x}.$$

Задача. Доказать, что это решение — это псевдорешение

$$\begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \dots & \dots \\ x_n & 1 \end{pmatrix} \begin{pmatrix} k \\ b \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix}.$$

Семинар 2

Псевдорешение:

$$\begin{aligned}\begin{pmatrix} k \\ b \end{pmatrix} &= \begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \dots & \dots \\ x_n & 1 \end{pmatrix}^+ \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix} = \\ &= \frac{1}{n} \frac{1}{\bar{x}^2 - \bar{x}^2} \begin{pmatrix} 1 & -\bar{x} \\ -\bar{x} & \bar{x}^2 \end{pmatrix} \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ 1 & 1 & \dots & 1 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix} = \\ &= \frac{1}{n} \frac{1}{\bar{x}^2 - \bar{x}^2} \begin{pmatrix} 1 & -\bar{x} \\ -\bar{x} & \bar{x}^2 \end{pmatrix} \begin{pmatrix} n\bar{x}\bar{y} \\ n\bar{y} \end{pmatrix}.\end{aligned}$$

Легко видеть, что

$$k = \frac{\bar{x}\bar{y} - \bar{x}\bar{y}}{\bar{x}^2 - \bar{x}^2}$$

Равенство $b = \bar{y} - k\bar{x}$ оставим как упражнение.