

# Прикладная статистика в машинном обучении

## Семинар 5

### Регрессионный анализ

И. К. Козлов  
(Мехмат МГУ)

2022

# Нелинейная регрессия

## 1 Нелинейная регрессия

## 2 PCA

## 3 Доверительные интервалы

- Оценки ошибок
- Оценки предсказаний

# Нелинейная регрессия

Почему мы аппроксимируем функцию только линейными?

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_m x_{im} + \varepsilon_i$$

Простейшее обобщение — аппроксимировать линейной комбинацией функций

$$y_i = \beta_0 + f_1(x) \beta_1 + \dots + f_m(x) \beta_m + \varepsilon_i$$

# Подгонка полинома

## Подгонка полинома.

Мы хотим приблизить точки  $(x_i, y_i)$  полиномом степени  $m - 1$ :

$$y_i = \beta_0 + x_i \beta_1 + x_i^2 \beta_2 + \cdots + x_i^{m-1} \beta_{m-1}.$$

Какая будет матрица  $X$ ?

# Подгонка полинома

## Подгонка полинома.

Мы хотим приблизить точки  $(x_i, y_i)$  полиномом степени  $m - 1$ :

$$y_i = \beta_0 + x_i \beta_1 + x_i^2 \beta_2 + \dots + x_i^{m-1} \beta_{m-1}.$$

Какая будет матрица  $X$ ?

**А:** Матрица Вандермонда

$$\begin{pmatrix} 1 & x_1 & \dots & x_1^{n-1} \\ 1 & x_2 & \dots & x_2^{n-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \dots & x_n^{n-1} \end{pmatrix}.$$

# PCA

1 Нелинейная регрессия

2 PCA

3 Доверительные интервалы

- Оценки ошибок
- Оценки предсказаний

**Q:** К какому виду можно привести симметричную билинейную форму

$$B(u, v) = B(v, u), \quad B(u + v, w) = B(u, w) + B(v, w), \quad B(\lambda v, w) = \lambda B(v, w)$$

в евклидовом пространстве  $\mathbb{R}^n$ ?

## Главные оси

- $B$  — симметричная билинейная форма,
- $Q$  — скалярное произведение (=симметричная положительно определённая билинейная форма),

Приведение пары форм к главным осям:

$$B = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{bmatrix} \quad Q = \begin{bmatrix} 1 & & & \\ & 1 & & \\ & & \ddots & \\ & & & 1 \end{bmatrix}$$




**Q:** Какой известный объект в Статистике — симметричная билинейная форма?

**Q:** Какой известный объект в Статистике — симметричная билинейная форма?

**A:** Матрица ковариации


$$\text{Cov}[X_i, X_j] = \mathbb{E}[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])]$$




# Главные оси

Приводим матрицу ковариации к диагональному виду.

Проецируем данные на оси (главные компоненты).




В 2-D проецируем на прямую - 1ую главную компоненту



# SVD

Одномерная регрессия — подгонка прямой под облако точек.



Q: Эта прямая — первая главная компонента в PCA или нет?

## Дилемма смещения-дисперсия

Разница между одномерной регрессией и PCA:




Рис.: PCA vs Linear Regression

# Доверительные интервалы

1 Нелинейная регрессия

2 PCA

3 Доверительные интервалы

- Оценки ошибок
- Оценки предсказаний

## Доверительные интервалы

Насколько хороши предсказания регрессия?  
Построим доверительные интервалы.




Рис.: Доверительный интервал для регрессии

# Гауссовский шум

Гауссовский шум.

Далее будем считать, что шум

$$\varepsilon = (\varepsilon_1, \dots, \varepsilon_n)$$

имеет нормальное распределение.



# Оценки ошибок

- 1 Нелинейная регрессия
- 2 РСА
- 3 Доверительные интервалы
  - Оценки ошибок
  - Оценки предсказаний

# Нейронки — о дивный новый мир

Начнём с оценок для **дисперсии ошибок  $\sigma^2$** .

## Теорема

Несмещённая оценка для  $\sigma^2$  — это

$$\hat{\sigma}^2 = \frac{1}{n - m} \text{RSS} = \frac{1}{n - m} \sum_{i=1}^n \hat{\varepsilon}_i^2.$$

# Нейронки — о дивный новый мир

Начнём с оценок для **дисперсии ошибок  $\sigma^2$** .

## Теорема

Несмещённая оценка для  $\sigma^2$  — это

$$\hat{\sigma}^2 = \frac{1}{n-m} \text{RSS} = \frac{1}{n-m} \sum_{i=1}^n \hat{\varepsilon}_i^2.$$

Более того,

❶ RSS независит от оценки  $\hat{\beta}$ ;

❷  $\frac{1}{\sigma^2} \text{RSS} \sim \chi_{n-m}^2$ .

- **Шаг 0.** Для распределения хи-квадрат  $R_k \sim \chi_k^2$  матожидание  $\mathbb{E}(R_k) = k$ .

По определению

$$R_k \sim \chi_k^2 \iff R_k = Z_1^2 + \dots + Z_k^2, \quad Z_j \sim \mathcal{N}(0, 1).$$

Поэтому

$$\mathbb{E}(R_k) = \sum_j \mathbb{E}(Z_j^2) = k \mathbb{V}(Z_j) = k.$$

# Несмещённость

- **Шаг 1.** Из  $\frac{1}{\sigma^2} \text{RSS} \sim \chi_{n-m}^2$  вытекает несмещённость  $\hat{\sigma}^2 = \frac{1}{n-m} \text{RSS}$ .

## Несмещённость

- **Шаг 1.** Из  $\frac{1}{\sigma^2} \text{RSS} \sim \chi_{n-m}^2$  вытекает несмещённость  $\hat{\sigma}^2 = \frac{1}{n-m} \text{RSS}$ .


Согласно Шагу 0:

$$\mathbb{E}\left(\frac{1}{\sigma^2} \text{RSS}\right) = n - m \quad \Rightarrow \quad \mathbb{E}(\hat{\sigma}^2) = \sigma^2.$$

# Проекция нормального распределения

Вспомним свойство **многомерного нормального распределения**.

- Пусть случайный вектор  $\xi \sim \mathcal{N}(0, \sigma^2 I_n)$ .
- $L_1$  и  $L_2$  — ортогональные подпространства в  $\mathbb{R}^n$ .



## Лемма 1

- 1 Проекции  $\Pi_{L_1}\xi$  и  $\Pi_{L_2}\xi$  независимы и нормально распределены.
- 2  $\frac{1}{\sigma^2} \|\Pi_{L_i}\xi\|^2 \sim \chi_{\dim L_i}^2$ .

## Распределение ошибок


- Шаг 2.  $\frac{1}{\sigma^2} \text{RSS} \sim \chi^2_{n-m}$ .



## Распределение ошибок

- Шаг 2.  $\frac{1}{\sigma^2} \text{RSS} \sim \chi_{n-m}^2$ .

Обозначим  $L = L(X)$ .



Вектор остатков — это проекция на  $L^\perp$ :

$$\hat{\varepsilon} = \Pi_{L^\perp} Y.$$

## Распределение ошибок

По условию  $Y = X\beta + \varepsilon$ . Вектор  $X \in L$ , поэтому

$$\hat{\varepsilon} = \Pi_{L^\perp} Y = \Pi_{L^\perp} \varepsilon.$$

По Лемме 1

$$\frac{1}{\sigma^2} \text{RSS} = \frac{1}{\sigma^2} \|\hat{\varepsilon}\|^2 \sim \chi_{n-m}^2.$$

**Шаг 2 доказан.**

# Независимость

- Шаг 3. RSS *независит* от оценки  $\hat{\beta}$ .

Есть два разложения  $Y$ :

$$Y = X\hat{\beta} + \hat{\varepsilon} = X\beta + \varepsilon.$$

Рассмотрим проекции  $Y$  на  $L$  и  $L^\perp$ .

$$\Pi_{L^\perp} Y = \hat{\varepsilon} = \Pi_{L^\perp} \varepsilon.$$

$$\Pi_L Y = X\hat{\beta} = X\beta + \Pi_L \varepsilon.$$

По Лемме 1 они независимы. Получаем, что

$$\hat{\beta} = \beta + (X^T X)^{-1} \Pi_L \varepsilon.$$

$\hat{\beta}$  и  $\hat{\varepsilon} = \Pi_{L^\perp} \varepsilon$  независимы как функции от независимых случайных величин.

# Оценки предсказаний

1 Нелинейная регрессия

2 РСА

3 Доверительные интервалы

- Оценки ошибок

- Оценки предсказаний

## Оценки предсказаний

Пусть мы построили модель регрессии

$$\hat{r}(x) = \hat{\beta}_0 + x\hat{\beta}_1$$

по данным  $(x_1, Y_1), \dots, (x_n, Y_n)$ .

Попробуем предсказать значение  $Y$  в новой точке  $X = x_*$ .

## Оценки предсказаний

- Предсказанное значение

$$\hat{Y}_* = \hat{\beta}_0 + x_* \hat{\beta}_1$$

- Истинное значение

$$Y_* = \beta_0 + x_* \beta_1 + \epsilon.$$

Q: Равны ли дисперсии  $\mathbb{V}(\hat{Y}_*)$  и  $\mathbb{V}(Y)$ ?

## Оценки предсказаний

- Предсказанное значение

$$\hat{Y}_* = \hat{\beta}_0 + x_* \hat{\beta}_1$$

- Истинное значение


$$Y_* = \beta_0 + x_* \beta_1 + \epsilon.$$

**Q:** Равны ли дисперсии  $\mathbb{V}(\hat{Y}_*)$  и  $\mathbb{V}(Y)$ ?


**A:** Нет, не учитывается шум  $\epsilon$ :

$$\mathbb{V}(Y) = \mathbb{V}(\hat{Y}_*) + \sigma^2.$$

При предсказании  $\hat{Y}_* = X_* \hat{\beta}$  мы допускаем 2 ошибки:



Параметры  $\hat{\beta} \neq \beta$



Есть шум:  $Y_* = X_* \beta + \epsilon$



Отсюда возникает поправка в доверительном интервале:

**13.11 Theorem** (Prediction Interval). *Let*

$$\hat{\xi}_n^2 = \hat{\sigma}^2 \left( \frac{\sum_{i=1}^n (X_i - X_*)^2}{n \sum_i (X_i - \bar{X})^2} + 1 \right). \quad (13.16)$$

*An approximate  $1 - \alpha$  prediction interval for  $Y_*$  is*

$$\hat{Y}_* \pm z_{\alpha/2} \hat{\xi}_n. \quad (13.17)$$