

Прикладная статистика в машинном обучении

Лекция 9


Байесовский взгляд на подбор моделей

И. К. Козлов
(Мехмат МГУ)

2022

В прошлый раз мы совершили “эволюцию сознания”, познав [формулу Байеса](#)

$$p(\theta | x^n) = \frac{p(x^n | \theta) p(\theta)}{\int p(x^n | \theta) p(\theta) d\theta}.$$



Вспомним — какая на прошлом занятии была
главная проблема с байесовским выводом?

PREVIOUS
EPIISODES

Сопряжённые распределения

- **Проблема.** Может не считаться знаменатель в теореме Байеса

$$\int p(x^n | \theta) p(\theta) d\theta.$$

Сопряжённые распределения

- **Проблема.** Может не считаться знаменатель в теореме Байеса

$$\int p(x^n | \theta) p(\theta) d\theta.$$

- **Решение.** Рассматривать **сопряжённые** семейства распределений:

- Априорное $p(\theta)$ — из \mathcal{A} ,
- Функция правдоподобия $p(x^n | \theta)$ — из \mathcal{B} .
- Апостериорное $p(\theta | x^n)$ — тоже из \mathcal{A} .

Сопряжённые распределения

- **Проблема.** Может не считаться знаменатель в теореме Байеса

$$\int p(x^n | \theta) p(\theta) d\theta.$$

- **Решение.** Рассматривать **сопряжённые** семейства распределений:
 - Априорное $p(\theta)$ — из \mathcal{A} ,
 - Функция правдоподобия $p(x^n | \theta)$ — из \mathcal{B} .
 - Апостериорное $p(\theta | x^n)$ — тоже из \mathcal{A} .
- **Вопрос:** Есть ли большое семейство распределений, для которого известно сопряжённое семейство, и легко производить байесовский вывод?

Экспоненциальное семейство распределений

1 Экспоненциальное семейство распределений

2 Достаточные статистики

- Теорема Рао–Блэквелла–Колмогорова

3 Байесовский подход к ML

- Этап обучения
- Этап тестирования

4 Принцип максимума обоснованности

Экспоненциальный класс

Экспоненциальный класс

Семейство распределений, чья плотность может быть представлена в виде:

$$f(x|\theta) = \frac{h(x)}{g(\theta)} \exp\left(\theta^T u(x)\right),$$

Экспоненциальный класс

Семейство распределений, чья плотность может быть представлена в виде:

$$f(x|\theta) = \frac{h(x)}{g(\theta)} \exp\left(\theta^T u(x)\right),$$

- $h(x) \geq 0$,
- $\theta^T u(x)$ означает $\theta_1 u_1(x) + \dots + \theta_k u_k(x)$,
- Чтобы интеграл от плотности равнялся единице:


$$g(\theta) = \int h(x) \exp\left(\theta^T u(x)\right) dx.$$

Экспоненциальный класс



- normal
- exponential
- gamma
- Bernoulli
- Poisson
- binomial (fixed number of trials)
- multinomial (fixed number of trials)
- negative binomial (fixed number of failures)
- categorical
- chi-squared
- beta
- Dirichlet
- geometric


Большинство стандартных распределений



Uniform
Distributions



Student



Mixtures

Сопряжённые семейства

Для экспоненциального класса легко строятся *сопряжённые семейства*.

Рассмотрим экспоненциальный класс:

$$f(x|\theta) = \frac{h(x)}{g(\theta)} \exp\left(\theta^T u(x)\right),$$

Сопряжённые семейства

Для экспоненциального класса легко строятся *сопряжённые семейства*.

Рассмотрим экспоненциальный класс:

$$f(x|\theta) = \frac{h(x)}{g(\theta)} \exp(\theta^T u(x)),$$

Посмотрим на него, как на функцию от θ :

$$\frac{C}{g(\theta)^\nu} \exp(\text{Линейно по } \theta). \quad (1)$$

Замечание. Семейство вида (1) сохраняется при умножении на $f(x|\theta)$. Это и есть сопряжённое семейство.

Сопряжённые семейства

Для экспоненциального класса

$$f(x | \theta) = \frac{h(x)}{g(\theta)} \exp(\theta^T u(x))$$

сопряжённым является семейство

$$g(\theta | \chi, \nu) = \frac{q(\chi, \nu)}{g(\theta)^\nu} \exp(\theta^T \chi).$$

Сопряжённые семейства

Для экспоненциального класса

$$f(x | \theta) = \frac{h(x)}{g(\theta)} \exp(\theta^T u(x))$$

сопряжённым является семейство

$$g(\theta | \chi, \nu) = \frac{q(\chi, \nu)}{g(\theta)^\nu} \exp(\theta^T \chi).$$

Находим **апостериорное распределение** — произведение априорного на правдоподобия (т.е. на произведение вероятности выборки):

$$\begin{aligned} f(X | \theta) g(\theta | \chi, \nu) &= \prod_{i=1}^n f(x_i | \theta) g(\theta | \chi, \nu) \propto \\ &\propto \frac{1}{g(\theta)^{\nu+n}} \exp(\theta^T \left[\chi + \sum_{i=1}^n u(x_i) \right]). \end{aligned}$$

Сопряжённые семейства

Элементарно находится апостериорное распределение.

Параметры апостериорного семейства:

$$\nu' = \nu + n, \quad \chi' = \chi + \sum_{i=1}^n u(x_i)$$

Да, весь байесовский вывод - в 1 строчку, пару функций сложить.

Сопряжённые семейства

“Физический смысл” параметров априорного распределения:

- ν — число наблюдений.
- χ — сумма **достаточных статистик** $u(x_i)$.

Далее обсудим — что такое достаточные статистики, и какие у них основные свойства.

Достаточные статистики

1 Экспоненциальное семейство распределений

2 Достаточные статистики

- Теорема Рао–Блэквелла–Колмогорова

3 Байесовский подход к ML

- Этап обучения
- Этап тестирования

4 Принцип максимума обоснованности

Ужать информацию

Иногда хочется оставить только самое нужное,
и ужать информацию *покомпактней*.



Достаточные статистики

Пусть X — i.i.d. выборка из F_θ .

Достаточная статистика — статистика $T = T(X)$, которая содержит в себе всю информацию о параметре θ , содержащуюся в выборке X .

Формально, $T = T(X)$ — достаточная статистика, если

$$\mathbb{P}(X \mid T(X) = t, \theta) = \mathbb{P}(X \mid T(X) = t).$$

Достаточные статистики

Простейший пример достаточной статистики — вся выборка X .


Хочется хранить информацию покомпактней.

Достаточные статистики

Пример-2. Рассмотрим схему Бернулли (“монетка”).

Достаточная статистика T — число выпавших орлов. Если фиксировать $T = t$, то все варианты $X = x$ равновероятны.

Вероятности $P(X = x \mid T = t)$ **не зависят** от вероятности выпадения орла θ .



Достаточные статистики

Пусть $f(x|\theta)$ — плотность распределения.

Простой критерий для достаточных статистик.

Теорема факторизации Фишера

$T(x)$ — достаточная статистика \Leftrightarrow существует разложение

$$f(x | \theta) = h(x) q(\theta, T(x)).$$

Грубо говоря, *всё, что в плотности зависит от θ , встречается вместе с $T(x)$.*

Докажем теорему факторизации на семинаре.

Достаточные статистики

Напрашивающийся пример. Плотность для экспоненциального класса

$$f(x \mid \theta) = h(x) \cdot \frac{1}{g(\theta)} \exp\left(\theta^T u(x)\right)$$

имеет требуемый вид

$$f(x \mid \theta) = h(x) \cdot q(\theta, T(x)).$$

Достаточная статистика $T(x) = u(x)$.

Достаточные статистики

У экспоненциального класса **конечное число** k достаточных статистик

$$u_1(X), \quad \dots, \quad u_k(X).$$

Оказывается, “другого такого класса не найти”:

Достаточные статистики

У экспоненциального класса **конечное число** k достаточных статистик

$$u_1(X), \quad \dots, \quad u_k(X).$$

Оказывается, “другого такого класса не найти”:

Среди гладких семейств распределений $f(x; \theta)$ с фиксированным носителем

$$\{x : f(x; \theta) > 0\}$$

только у экспоненциальных семейств существуют непрерывные k -мерные достаточные статистики.

Подробнее — см. Глава 10, §3, Теорема 2



М. Б. Лагутин,

Наглядная математическая статистика.

Теорема Рао–Блэквелла–Колмогорова

1 Экспоненциальное семейство распределений

2 Достаточные статистики

- Теорема Рао–Блэквелла–Колмогорова

3 Байесовский подход к ML

- Этап обучения
- Этап тестирования

4 Принцип максимума обоснованности

Теорема Рао–Блэквелла–Колмогорова

Достаточные статистики делают несмещённые оценки лучше.

- Пусть T — достаточная статистика;
- $\hat{\theta}$ — несмещённая оценка на θ и $\mathbb{V}\hat{\theta} < \infty$.

Теорема Рао–Блэквелла–Колмогорова

Достаточные статистики делают несмещённые оценки лучше.

- Пусть T — достаточная статистика;
- $\hat{\theta}$ — несмещённая оценка на θ и $\mathbb{V}\hat{\theta} < \infty$.

Теорема Рао–Блэквелла–Колмогорова

Оценка

$$\hat{\theta}_T = \mathbb{E}(\hat{\theta} \mid T)$$

- будет несмещённой оценкой

$$\mathbb{E}\hat{\theta}_T = \theta,$$

- с меньшей дисперсией

$$\mathbb{V}\hat{\theta}_T \leq \mathbb{V}\hat{\theta}.$$

Теорема Рао–Блэквелла–Колмогорова

Доказательство.

- Оценка — это функция от выборки x_1, \dots, x_n . Она не должна зависеть от θ .

Проверим, что $\hat{\theta}_T = \mathbb{E}(\hat{\theta} \mid T)$ не зависит от θ .

Теорема Рао–Блэквелла–Колмогорова

Доказательство.

- Оценка — это функция от выборки x_1, \dots, x_n . Она не должна зависеть от θ .

Проверим, что $\hat{\theta}_T = \mathbb{E}(\hat{\theta} \mid T)$ не зависит от θ .

Действительно, по определению условного математического ожидания

$$\mathbb{E}(\hat{\theta} \mid T) = \int \hat{\theta}(x) p(x \mid T = t, \theta) dx.$$

Поскольку T — достаточная статистика, $p(x \mid T = t, \theta) = p(x \mid T = t)$.

Поэтому интеграл (и $\hat{\theta}_T$) не зависит от θ .

Теорема Рао–Блэквелла–Колмогорова

- Докажем несмещённость

$$\mathbb{E}\hat{\theta}_T = \theta.$$

Q: Мы встречались с выражением вида $\mathbb{E}(\mathbb{E}(X \mid Y))$?

Теорема Рао–Блэквелла–Колмогорова

- Докажем несмещённость

$$\mathbb{E}\hat{\theta}_T = \theta.$$

Q: Мы встречались с выражением вида $\mathbb{E}(\mathbb{E}(X \mid Y))$?

A: Вспоминаем: “матожидание убирает условие”. Используем несмещённость $\hat{\theta}$:

$$\mathbb{E}\hat{\theta}_T = \mathbb{E}[\mathbb{E}(\hat{\theta} \mid T)] = \mathbb{E}\hat{\theta} = \theta.$$

Теорема Рао–Блэквелла–Колмогорова

- Дисперсия не увеличивается

$$\mathbb{V}\hat{\theta} \geq \mathbb{V}\hat{\theta}_T.$$

Q: Мы встречались с выражением вида $\mathbb{V}(\mathbb{E}(X \mid Y))$?

Теорема Рао–Блэквелла–Колмогорова

- Дисперсия не увеличивается

$$\mathbb{V}\hat{\theta} \geq \mathbb{V}\hat{\theta}_T.$$

Q: Мы встречались с выражением вида $\mathbb{V}(\mathbb{E}(X \mid Y))$?

A: Да, утверждение следует из закона полной дисперсии

$$\mathbb{V}(\mathbb{E}[X \mid Y]) = \mathbb{V}(X) - \mathbb{E}[\mathbb{V}(X \mid Y)].$$

Теорема Рао–Блэквелла–Колмогорова доказана.

Перерыв

Байес в ML

Во 2ой части лекции поговорим про Байес в ML:

- ❶ Формулировка и схема решения ML-задач на байесовском языке.
- ❷ Принцип максимума обоснованности.
Объясним как сравнивать модели = перебирать гиперпараметры.

Байесовский подход к ML

1 Экспоненциальное семейство распределений

2 Достаточные статистики

- Теорема Рао–Блэквелла–Колмогорова

3 Байесовский подход к ML

- Этап обучения
- Этап тестирования

4 Принцип максимума обоснованности

ML-модели

ML-модели — по сути отображения

$$\text{Data} \xrightarrow{F_\theta} \text{Target}.$$

Скажем, по картинке предсказываем метку класса

$$f(\text{img}) \rightarrow \text{cat}$$

Вероятностный подход к ML

Мы рассматриваем **вероятностные модели** — совместные распределения на интересующие нас переменные.

Будет 3 группы переменных X, T, θ :

- X — наблюдаемые переменные (Data).
- T — это целевые переменные (Target).
- θ — параметры модели.

2 типа моделей

В курсе встречается 2 типа моделей.

Ниже обсудим дискриминативные модели, для генеративных рассуждения аналогичны.

Дискриминативные

$$p(t, \theta | x) = p(t | x, \theta)p(\theta)$$

При известном x можно предсказывать значение t .

Генеративные

$$p(x, t, \theta) = p(x | t, \theta)p(t | \theta)p(\theta)$$

Можно генерировать x .

2 типа моделей

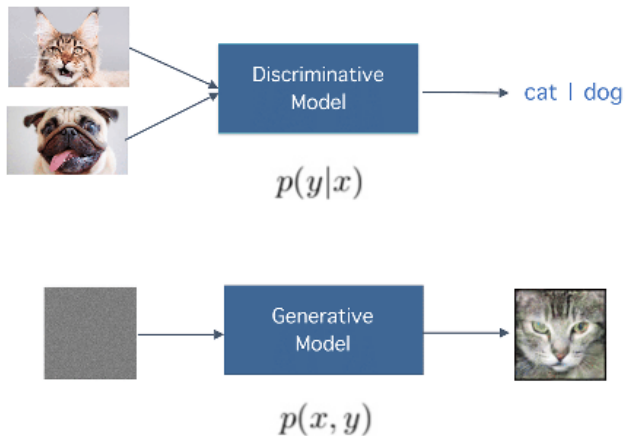



Рис.: Мы с ними уже сталкивались

2 типа моделей

Как обычно, при работе с ML-моделями, данные поделены на **Train** и **Test**.

- Обучаем модель на **Train** (т.е. на X_{tr}, T_{tr}).
- Затем предсказываем ответы для **Test** (по x_{test} угадываем t_{test}).



Этап обучения

1 Экспоненциальное семейство распределений

2 Достаточные статистики

- Теорема Рао–Блэквелла–Колмогорова

3 Байесовский подход к ML

- Этап обучения
- Этап тестирования

4 Принцип максимума обоснованности

Классический подход.

Дискриминативная модель — это задание функции правдоподобия

$$p(t \mid x, \theta).$$

Если знаем данные x и параметры модели θ , то можем найти метку t .

Классический подход.

Дискриминативная модель — это задание функции правдоподобия

$$p(t \mid x, \theta).$$

Если знаем данные x и параметры модели θ , то можем найти метку t .

Q: Как найти параметры модели θ ?

Классический подход.

Дискриминативная модель — это задание функции правдоподобия

$$p(t \mid x, \theta).$$

Если знаем данные x и параметры модели θ , то можем найти метку t .

Q: Как найти параметры модели θ ?

A: Например, оценкой максимума правдоподобия:

$$\hat{\theta}_{\text{ML}} = \operatorname{argmax}_{\theta \in \Theta} p(T_{tr} \mid X_{tr}, \theta) = \operatorname{argmax}_{\theta \in \Theta} \prod_{i=1}^N p(t_i \mid x_i, \theta)$$

Байесовский подход.

- Известна функция правдоподобия $p(t | x, \theta)$.
- Задаём априорное распределение $p(\theta)$.

Q: Что дальше делают байесиане?

Байесовский подход.

- Известна функция правдоподобия $p(t | x, \theta)$.
- Задаём априорное распределение $p(\theta)$.


Q: Что дальше делают байесиане?

A: Ну конечно, байесовский вывод на неизвестные параметры:

$$p(\theta | X_{tr}, T_{tr}) = \frac{p(T_{tr} | X_{tr}, \theta)p(\theta)}{\int p(T_{tr} | X_{tr}, \theta)p(\theta)d\theta}.$$

$$p(\theta \mid X_{tr}, T_{tr}) = \frac{p(T_{tr} \mid X_{tr}, \theta)p(\theta)}{\int p(T_{tr} \mid X_{tr}, \theta)p(\theta)d\theta}.$$

А вот и он — архивраг всех аналитических байесиан — неберущийся интеграл.



Worst Case Scenario


Рассмотрим худший случай — интеграл не считается.

Мы знаем распределение с точностью до константы

$$p(\theta \mid X_{tr}, T_{tr}) = \frac{p(T_{tr} \mid X_{tr}, \theta)p(\theta)}{Z}.$$

Q: Что можно сделать? (Что не меняется у функции при умножении на константу?)

WORST CASE
SCENARIO




MAP-оценка

При умножении на константу мода не меняется.

MAP-оценка (Maximum a posteriori) — это **апостериорный максимум**:

$$\theta_{MP} = \arg \max_{\theta} p(\theta \mid X_{tr}, T_{tr})$$



MAP-оценка

Замечание. MAP-оценка — это поправка MLE θ_{ML} :

$$\begin{aligned}\theta_{MP} &= \arg \max_{\theta} p(T_{tr} | X_{tr}, \theta) p(\theta) = \\ &= \arg \max_{\theta} [\ln p(T_{tr} | X_{tr}, \theta) + \ln p(\theta)] .\end{aligned}$$

Этап тестирования

1 Экспоненциальное семейство распределений

2 Достаточные статистики

- Теорема Рао–Блэквелла–Колмогорова

3 Байесовский подход к ML

- Этап обучения
- Этап тестирования

4 Принцип максимума обоснованности


Классический подход.

- Выбраны параметры модели θ_{ML} .
- Дан объект x_{test} .
- Нужно оценить неизвестное t_{test} .

Классический подход.

- Выбраны параметры модели θ_{ML} .
- Дан объект x_{test} .
- Нужно оценить неизвестное t_{test} .

Всё просто — предсказываем $p(t_{test} \mid x_{test}, \theta_{ML})$.



$[0.7, 0.3]$
cat dog

Байесовский подход.

Наша цель — вычислить вероятность

$$p(t_{test} \mid x_{test}, X_{tr}, T_{tr}).$$

- Видели обучающую выборку X_{tr}, T_{tr} , знаем объект x_{test} .
- Хотим знать вероятности меток t_{test} .

Q: Как это сделать? Какие распределения мы знаем?

Тестирование. Байес

Известны:

- апостериорное распределение на параметры модели:

$$p(\theta \mid X_{tr}, T_{tr})$$

- функция правдоподобия

$$p(t_{test} \mid x_{test}, \theta)$$

Q: Как вычислить $p(t_{test} \mid x_{test}, X_{tr}, T_{tr})$?

Тестирование. Байес

Известны:

- апостериорное распределение на параметры модели:

$$p(\theta \mid X_{tr}, T_{tr})$$

- функция правдоподобия

$$p(t_{test} \mid x_{test}, \theta)$$

Q: Как вычислить $p(t_{test} \mid x_{test}, X_{tr}, T_{tr})$?

В байесовском случае усредняем предсказания моделей по апостериорному распределению на параметр:

$$p(t_{test} \mid x_{test}, X_{tr}, T_{tr}) = \int p(t_{test} \mid x_{test}, \theta) p(\theta \mid X_{tr}, T_{tr}) d\theta.$$

Метод Монте-Карло

Замечание. Даже если распределение известно с точностью до константы, из него можно **сэмплировать**.

Предсказание модели можно оценить **методом Монте-Карло** (см. Лекцию 3):

$$p(t_{test} | x_{test}, X_{tr}, T_{tr}) = \int p(t_{test} | x_{test}, \theta) p(\theta | X_{tr}, T_{tr}) d\theta \approx \frac{1}{K} \sum_{k=1}^K p(t_{test} | x_{test}, \theta_k),$$

где $\theta_k \sim p(\theta | X_{tr}, T_{tr})$, т.е. сгенерирована из апостериорного распределения.

Принцип максимума обоснованности

1 Экспоненциальное семейство распределений

2 Достаточные статистики

- Теорема Рао–Блэквелла–Колмогорова

3 Байесовский подход к ML

- Этап обучения
- Этап тестирования

4 Принцип максимума обоснованности

Выбор моделей

Очень кратко обсудим байесовский способ отбора моделей.

Подробнее — см. Главу 3.4.



Bishop C.M.

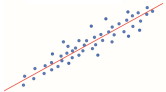
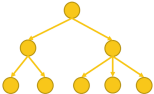
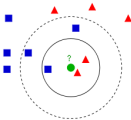
Pattern Recognition and Machine Learning.

Выбор модели

Что нам дано?

Есть несколько моделей (занумеруем их $\mathcal{M} = 1, \dots, M$).

У каждой из них — свои параметры w .

Модели	Линейная регрессия	Decision Tree	KNN
Параметры	 <p>Веса w</p>	 <p>Глубина</p>	 <p>Число соседей N</p>

Выбор модели

Нам даны:

- Модели \mathcal{M} .
- Обучающая выборка (X_{tr}, Y_{tr}) .

Q: Какую модель выбрал бы “байесовский человек”?

Выбор модели

Нам даны:

- Модели \mathcal{M} .
- Обучающая выборка (X_{tr}, Y_{tr}) .

Q: Какую модель выбрал бы “байесовский человек”?

A: Наиболее вероятную при таких данных $\arg \max \mathbb{P}(\mathcal{M} \mid Y_{tr}, X_{tr})$.

Принцип наибольшей обоснованности

Теорема Байеса — универсальное решение всех проблем.

Поступаем “по-байесовски”:

- Вводим априорное распределение на модели $\mathbb{P}(\mathcal{M})$.
- По формуле Байеса

$$\mathbb{P}(\mathcal{M} \mid Y_{tr}, X_{tr}) = \frac{\mathbb{P}(Y_{tr} \mid X_{tr}, \mathcal{M}) \mathbb{P}(\mathcal{M})}{\mathbb{P}(Y_{tr} \mid X_{tr})}.$$

- **Q:** Если нам нужна конкретная модель, а не распределение — какую брать?

Максимум обоснованности.

- Если нужна точка — берём MAP-оценку

$$\mathcal{M}_{MP} = \arg \max_{\mathcal{M}} \mathbb{P}(Y_{tr} | X_{tr}, \mathcal{M}) \mathbb{P}(\mathcal{M}).$$

- Первое слагаемое $\mathbb{P}(Y_{tr} | X_{tr}, \mathcal{M})$ называется **обоснованностью** (evidence).
- Если для нас модели равновероятны, то получается **принцип максимума обоснованности**.

$$\mathcal{M}_{ME} = \arg \max_{\mathcal{M}} \mathbb{P}(Y_{tr} | X_{tr}, \mathcal{M}).$$

Принцип наибольшей обоснованности

У модели \mathcal{M} параметры w .

Мы умеем считать вероятности при фиксированных параметрах $\mathbb{P}(Y_{tr} | X_{tr}, w)$.

Q: Как посчитать обоснованность модели $\mathbb{P}(Y_{tr} | X_{tr}, \mathcal{M})$?

A: Нужно усреднить предсказание по распределению на параметры:

$$\mathbb{P}(Y_{tr} | X_{tr}, \mathcal{M}) = \int \mathbb{P}(Y_{tr} | X_{tr}, w) \mathbb{P}(w | \mathcal{M}) dw$$

Принцип наибольшей обоснованности

Подведём итоги.


Принцип максимума обоснованности

$$\mathcal{M}_{ME} = \arg \max_{\mathcal{M}} \mathbb{P}(Y_{tr} | X_{tr}, \mathcal{M})$$
$$\mathbb{P}(Y_{tr} | X_{tr}, \mathcal{M}) = \int \mathbb{P}(Y_{tr} | X_{tr}, w) \mathbb{P}(w | \mathcal{M}) dw.$$

Принцип наибольшей обоснованности

В целом, если обозначить данные за D , то метод максимизирует $\mathbb{P}(D \mid \mathcal{M})$.

Метод предпочитает модели, которые “дают ответы на меньшее число вопросов, но более уверенно”.



Принцип наибольшей обоснованности

Простой пример “наиболее обоснованной модели”.

Рассмотрим 3 кубика — с 4, 6 и 8 гранями. Выпало 5.

Q: Какая модель наиболее обоснованна?

Принцип наибольшей обоснованности

Простой пример “наиболее обоснованной модели”.

Рассмотрим 3 кубика — с 4, 6 и 8 гранями. Выпало 5.

Q: Какая модель наиболее обоснованна?

A: Кубик с 6 гранями — у него наибольшая вероятность $\mathbb{P}(\text{Data} \mid \mathcal{M}) = \frac{1}{6}$.




Всё чудесатее и чудесатее!

Сегодня мы взглянули на ML “по-байесовски”. Чудно!

А может ли эта абстрактная теория применяться на практике?

Конкретный пример — RVM — обсудим на следующем занятии.



← To Be Continued